

SdI30 W06: *ESTYMACJA PUNKTOWA PARAMETRÓW POPULACJI*

- 1. Estymacja punktowa i estymator parametru**
- 2. Własności estymatorów**
 - Przykład 1**
 - Przykład 2**
 - Przykład 3**
- 3. Metoda momentów wyznaczania estymatorów**
 - Przykład 4**
 - Przykład 5**
- 4. Metoda największej wiarygodności**
 - Przykład 6**
 - Przykład 7**
 - Przykład 8**

Przykład 9

- 5. Estymatory podstawowych charakterystyk liczbowych**
- 6. Szeregi: szczegółowy, pozycyjny i rozdzielczy**
- 7. Zestaw zadań**

1. Estymacja punktowa i estymator parametru

Estymacją punktową (point estimation) nazywamy metody statystyczne, służące do punktowego oszacowania wartości nieznanego parametru rozkładu cechy w populacji.

Niech rozkład badanej cechy X populacji zależy od nieznanego parametru θ . Parametr ten będziemy estymowali na podstawie SRS X_1, \dots, X_n pobranej z badanej populacji.

Estymatorem U_n nieznanego parametru θ rozkładu badanej cechy w populacji generalnej nazywamy każdą funkcję mierzalną próby losowej $U_n = h(X_1, X_2, \dots, X_n)$ – zwaną statystyką – służącą do oszacowania tego parametru.

Estymator U_n parametru θ oznaczamy $\hat{\theta}_n$.

Estymator jest zm. l. o rozkładzie zależnym od rozkładu zm. losowych tworzących próbę oraz od postaci funkcji h .

Oceną parametru θ nazywamy wartość liczbową $q_n = h(x_1, \dots, x_n)$ estymatora, otrzymaną na podstawie realizacji próby, tj. próbki x_1, \dots, x_n .

Ocena parametru prawie zawsze różni się od rzeczywistej wartości parametru θ .

Miarą błędu estymacji jest **błąd szacunku**

$$d = \hat{\theta}_n - \theta.$$

Spośród wielu estymatorów parametru θ powinniśmy wybierać estymator o „dobrych” własnościach.

2. Własności estymatorów

Statystyka $\hat{\theta}_n$ jest dobrym estymatorem nieznanego parametru θ , jeżeli ma odpowiednie własności.

Tymi własnościami są:

- nieobciążoność lub asymptotyczna nieobciążoność,
 - zgodność,
 - efektywność,
 - dostateczność.
-
- **Nieobciążoność.** Estymator $\hat{\theta}_n$ nazywamy *estymatorem nieobciążonym* parametru θ , jeśli
$$\mathbb{E}\hat{\theta}_n = \theta.$$

Uwaga. Jeśli cecha X populacji ma wartość oczekiwaną $m = \mathbb{E}X$ i wariancję $\sigma^2 = \mathbb{D}^2X$, to estymatorami nieobciążonymi tych charakterystyk liczbowych są średnia arytmetyczna i wariancja z prostej próby losowej X_1, \dots, X_n .

Jeśli

$$b(\hat{\theta}_n) \stackrel{\text{def.}}{=} \mathbb{E}\hat{\theta}_n - \theta \neq 0$$

to estymator nazywamy *estymatorem obciążonym*.

Różnicę $b(\hat{\theta}_n)$ nazywamy *obciążeniem estymatora*.

- **Asymptotyczna nieobciążoność**

Estymator nazywamy *asymptotycznie nieobciążonym*, gdy

$$\lim_{n \rightarrow \infty} b(\hat{\theta}_n) = 0.$$

Przykład 1. Niech X_1, \dots, X_n będzie SRS pobraną z populacji, w której cecha X ma skończoną i różną od zera wariancję σ^2 oraz $\mathbb{E}X = m$. Zbadać, czy statystyka

$$S_*^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \text{ gdzie } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

jest estymatorem nieobciążonym nieznanej wariancji σ^2 .

Rozwiązanie. Przekształcając S_*^2 otrzymujemy

$$\begin{aligned} S_*^2 &= \frac{1}{n} \sum_{i=1}^n \left((X_i - m) + (m - \bar{X}) \right)^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X} - m)^2 \end{aligned}$$

Ponieważ X_i są niezależnymi zmiennymi losowymi o tym samym rozkładzie co badana cecha X populacji, więc

$$\mathbb{E}(X_i - m)^2 = \mathbb{E}(X - m)^2 = \sigma^2 \text{ dla } i = 1, \dots, n,$$

a na podstawie własności wariancji

$$\mathbb{E}(\bar{X} - m)^2 = \mathbb{D}^2 \bar{X} = \mathbb{D}^2 \left(\frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n^2} \mathbb{D}^2 \sum_{i=1}^n X_i = \frac{\sigma^2}{n}$$

Zatem

$$\mathbb{E}S_*^2 = \frac{1}{n} n \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

Zatem statystyka ta jest obciążona, ale nie asymptotycznie.

Ponieważ $\mathbb{E}S^2 = \sigma^2$, gdzie $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, więc S^2 przyjmujemy za estymator nieznanej wariancji σ^2 .

Zgodność. Estymator $\hat{\theta}_n$ nazywamy *estymatorem zgodnym* parametru θ , jeśli jest stochastycznie zbieżny do szacowanego parametru, tj. dla każdego $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1$$

Jeśli rośnie liczebność próby, to rośnie prawd., przyjęcia przez estymator wartości coraz bliższych szacowanemu parametrowi. Tym samym zwiększając liczebność próby, zmniejszamy ryzyko popełnienia błędu.

Uwaga.

1. Z prawa wielkich liczb Czebyszewa wynika, że średnia arytmetyczna z próby jest zgodnym estymatorem wartości oczekiwanej w populacji generalnej, tzn.:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mathbb{E}X| < \varepsilon) = 1$$

2. Jeśli estymator $\hat{\theta}_n$ parametru θ jest zgodny, to jest asymptotycznie nieobciążony. Tw. odwrotne nie jest prawdziwe.
3. Jeśli estymator $\hat{\theta}_n$ parametru θ jest nieobciążony (lub asymptotycznie nieobciążony) oraz jeśli jego wariancja spełnia warunek

$$\lim_{n \rightarrow \infty} \mathbb{D}^2 \hat{\theta}_n = 0,$$

to $\hat{\theta}_n$ jest estymatorem zgodnym.

- **Efektywność**

Spośród wszystkich nieobciążonych estymatorów $U_{1,n}, U_{2,n}, \dots, U_{r,n}$ parametru θ , estymator o najmniejszej wariancji nazywamy *estymatorem najefektywniejszym*.

Do wyznaczenia najefektywniejszego estymatora potrzebna jest znajomość wariancji wszystkich estymatorów nieobciążonych danego parametru.

W praktyce korzystamy z *nierówności Rao-Cramera*.

http://pl.wikipedia.org/wiki/Nier%C3%B3wno%C5%9B%C4%87_Rao-Cram%C3%A9ra

Przykład 2. Zbadać, który z nieobciążonych estymatorów wartości oczekiwanej w populacji generalnej o dowolnym rozkładzie: średnia arytmetyczna, czy i -ta obserwacja X_i jest efektywniejszym estymatorem.

Rozwiązanie. Ponieważ

$$\mathbb{D}^2 \bar{X}_n = \frac{\mathbb{D}^2 X}{n} < \mathbb{D}^2 X_i = \mathbb{D}^2 X,$$

więc średnia arytmetyczna \bar{X}_n jest efektywniejszym estymatorem wartości oczekiwanej niż i -ta zmienna X_i z próby.

Przykład 3. Zbadać zgodność i efektywność empirycznego wskaźnika struktury \bar{P}_n , jako estymatora parametru p w rozkładzie Bernoulliego, $X \sim B(p)$.

Rozwiązanie. Niech X_1, \dots, X_n będzie prostą próbą z populacji $X \sim B(p)$.

Ponieważ

$$\mathbb{E}\bar{P}_n = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = p$$

oraz

$$\mathbb{D}^2 \bar{P}_n = \frac{1}{n^2} \sum_{i=1}^n \mathbb{D}^2 X_i = \frac{p(1-p)}{n}$$

i \bar{P}_n jest estymatorem o minimalnej wariancji, więc jest estymatorem zgodnym i najefektywniejszym dla parametru p .

• Dostateczność

Pojęcie dostateczności (wystarczalności) estymatora wprowadził Fisher¹. Estymator dostateczny parametru θ to taki estymator, który skupia w sobie wszystkie informacje o tym parametrze, tzn. żaden inny estymator nie zawiera w sobie więcej informacji o parametrze θ wyciągniętej z próby losowej.



¹ **Ronald Aylmer Fisher** (1890-1962) – genetyk i statystyk brytyjski. Twórca podstaw współczesnej statystyki. Stworzył m.in. statystyczną [metodę największej wiarygodności](#) (ang. *maximum likelihood*), [analizę wariancji](#) (ANOVA) oraz liniową analizę dyskryminacyjną.

3. Metoda momentów wyznaczania estymatorów

Wprowadzona około roku 1900 przez K. Pearsona.

Polega na przyjmowaniu momentów z próby jako estymatorów odpowiednich momentów rozkładu cechy w populacji ogólnej.

Momenty są zazwyczaj funkcjami parametrów θ_i rozkładu.

Z otrzymanego układu równań wyznacza się estymatory parametrów.

Niech X_1, \dots, X_n będzie SRS z populacji, w której badana cecha X ma pmf lub pdf $f(x)$.

Dla $k = 1, 2, 3, \dots$, wielkość $\mathbb{E}X^k$ jest k -tym momentem populacji, natomiast $\frac{1}{n} \sum_{i=1}^n X_i^k$ jest k -tym momentem z próby.

Stąd pierwszy moment populacji $\mathbb{E}X = m$, a pierwszy moment z próby \bar{X} .

Drugimi momentami populacji i próby są $\mathbb{E}X^2$ i $\frac{1}{n} \sum_{i=1}^n X_i^2$, odpowiednio.

Momenty populacji są funkcjami nieznanymi parametrów.

Niech X_1, \dots, X_n będzie SRS z populacji, w której badana cecha X ma pmf lub pdf $f(x; \theta_1, \dots, \theta_m)$, gdzie $\theta_1, \dots, \theta_m$ są parametrami, których wartości są nieznanne.

Estymatory tych parametrów metodą momentów (MM) uzyskuje się poprzez porównanie pierwszych m momentów próby z odpowiadającymi im momentami populacji.

Przykład 4. Różnica wskazań dowolnych dwóch przyrządów pomiarowych jest zmienną losową o rozkładzie jednostajnym w przedziale (a, b) . Oszacować metodą momentów końce przedziału.

Rozwiązanie. Ponieważ $X \sim u(a, b)$, więc

$$\mathbb{E}X = \frac{1}{2}(a + b), \quad \mathbb{D}X = \frac{1}{12}(b - a)^2,$$

Zastępując zgodnie z metodą momentów $\mathbb{E}X$ przez \bar{X}_n i $\mathbb{D}X$ przez S^2 otrzymujemy estymatory

$$a = \bar{X}_n - S\sqrt{3} \text{ oraz } b = \bar{X}_n + S\sqrt{3}.$$

Przykład 5. Niech badana cecha X ma rozkład gamma o gęstości

$$f(x|\alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\beta}} \mathbb{I}_{(0, \infty)}(x)$$

z nieznanymi parametrami $\alpha, \beta > 0$.

Wyznaczyć metodą momentów estymatory $\hat{\alpha}, \hat{\beta}$ parametrów α, β .

Następnie zastosować te estymatory do oceny tych parametrów na podstawie danych:

152	115	109	94	88	137	152	77	160	165
125	40	128	123	136	101	62	153	83	69

Rozwiązanie. Pierwsze dwa momenty zwykłe tego rozkładu dane są wzorami:

$$m_1 = \alpha\beta, m_2 = \alpha(\alpha + 1)\beta^2$$

Stąd na podstawie n -elementowej próby uzyskujemy równania

$$\alpha\beta = \bar{X}, \quad \alpha(\alpha + 1)\beta^2 = \frac{1}{n} \sum_1^n X_i^2$$

Wyznaczając z tych równań α i β , otrzymujemy estymatory

$$\hat{\alpha} = \frac{\bar{X}^2}{\frac{1}{n} \sum X_1^2 - \bar{X}^2},$$

$$\hat{\beta} = \frac{\frac{1}{n} \sum X_i^2 - \bar{X}^2}{\bar{X}}$$

Obliczenia ocen parametrów na podstawie danych

$$\bar{x} = 113,5 \text{ oraz } \frac{1}{20} \sum x_i^2 = 14087,8$$

stąd

$$\hat{\alpha} = \frac{(113,5)^2}{14087,8 - (113,5)^2} = 10,7$$

$$\hat{\beta} = \frac{14087,8 - (113,5)^2}{113,5} = 10,6$$

4. Metoda największej wiarygodności

Opracowana przez R. A. Fishera. Jest efektywniejsza od innych metod. Niech rozkład badanej cechy X zależy od k nieznanymi parametrów $\theta_1, \dots, \theta_k$, które chcemy oszacować.

Krok 1. Wyznaczamy funkcję wiarygodności próby:

$$L(x_1, \dots, x_n | \theta_1, \dots, \theta_k) = \prod_{i=1}^n f(x_i | \theta_1, \dots, \theta_k)$$

gdzie f oznacza PDF dla rozkładu typu ciągłego lub PMF dla rozkładu typu dyskretnego.

Krok 2. Za estymatory parametrów przyjmujemy $\hat{\theta}_1, \dots, \hat{\theta}_k$, dla których L (lub $\ln L$) przyjmuje wartość największą

Wartości maksymalizujące muszą spełniać układ równań

$$\frac{\partial \ln L}{\partial \theta_i} = 0 \quad \text{dla } i = 1, \dots, k$$

Krok 3. Sprawdzamy warunek konieczny i wystarczający dla maksimum funkcji. W szczególności dla $k = 1$ oznacza to, że druga pochodna w punkcie $\hat{\theta}$ jest ujemna.

Przykład 6. Cecha X pewnej populacji ma rozkład trzypunktowy z nieznanym parametrem p

$$f = \begin{pmatrix} -1 & 0 & 1 \\ 0,5 - p & 0,5 & p \end{pmatrix}$$

Wyznaczyć estymator parametru p

- a) metodą momentów,
- b) metodą największej wiarygodności.

Rozwiązanie. Niech x_1, x_2, \dots, x_n będzie realizacją próby prostej.

- a) W metodzie momentów wyznaczamy wartość oczekiwaną

$$m = \mathbb{E}X = 2p - \frac{1}{2}$$

czyli $p = (m + 1/2)/2$. Wstawiając moment empiryczny otrzymujemy estymator parametru p

$$\hat{p}_n = \frac{\bar{X}_n + \frac{1}{2}}{2}$$

b) Dla uproszczenia zapisu niech k oznacza liczbę obserwacji przyjmujących wartość -1 , a l – liczbę obserwacji przyjmujących wartość 0 .

Funkcja wiarygodności ma postać:

$$\begin{aligned} L(x_1, x_1, \dots, x_n | p) &= P(X_1 = x_1) \cdot \dots \cdot P(X_n = x_n) = \\ L(k, l, n | p) &= (0,5 - p)^k (0,5)^l p^{n-k-l} \end{aligned}$$

L osiąga maksimum w tym samym punkcie co funkcja $\ln L$.

$$\ln L(k, l, n | p) = k \ln(0,5 - p) + l \ln 0,5 + (n - k - l) \ln p$$

Funkcja $\ln L$ jest różniczkowalna względem p

$$\frac{d \ln L(k, l, n | p)}{dp} = 0$$

$$\frac{-k}{0,5 - p} + \frac{n - k - l}{p} = 0$$

Stąd

$$p = \frac{n - k - l}{2(n - l)}$$

Ostatecznie estymator wyraża się wzorem:

$$\hat{p} = \frac{n - U_1 - U_0}{2(n - U_0)}$$

gdzie U_1 i U_0 są statystykami zliczającymi wystąpienia odpowiednio wartości -1 i 0 (k i l są realizacjami tych statystyk).

Przykład 7. Wyznaczyć estymator parametru rozkładu wykładniczego

a) metodą MM;

b) metodą MNW.

Rozwiązanie b) Przyjmijmy, że dysponujemy n -elementową próbą z rozkładu wykładniczego $\text{Exp}(\lambda)$.

Poszukujemy estymatora funkcji parametrycznej $h(\lambda) = \frac{1}{\lambda}$.

Gęstość rozpatrywanego rozkładu ma postać:

$$f(x) = \lambda e^{-\lambda x}, \lambda > 0, x > 0$$

Kolejne kroki obliczeń są następujące:

$$L(\lambda; x_1, \dots, x_n) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

$$\ln L = n \ln \lambda - \lambda \sum_{i=1}^n x_i$$

$$\frac{\partial}{\partial \lambda} \ln L = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$$

$$\lambda = \frac{1}{\bar{x}}$$

$$\left. \frac{\partial^2}{\partial \lambda^2} \ln L \right|_{\lambda = \frac{1}{\bar{x}}} = -\frac{n}{\bar{x}} < 0$$

A zatem $\hat{\lambda} = \frac{1}{\bar{X}}$ jest estymatorem największej wiarygodności dla parametru λ .

Ostatecznie otrzymujemy:

$$\widehat{h(\lambda)} = \frac{1}{\hat{\lambda}} = \bar{X}$$

Otrzymany estymator nie jest nieobciążony, gdyż

$$\mathbb{E} \left(\frac{1}{\bar{X}} \right) \neq \frac{1}{\mathbb{E} \bar{X}}$$

Przykład 8. Niech X_1, \dots, X_n będzie SRS z rozkładu Weibulla o gęstości

$$f(x; \alpha, \beta) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} e^{-(x/\beta)^\alpha} \mathbf{1}_{[0, \infty)}(x)$$

Zapisując funkcję wiarygodności oraz jej logarytm i rozwiązując układ równań

$$\begin{cases} \frac{\partial}{\partial \alpha} [\ln L] = 0 \\ \frac{\partial}{\partial \beta} [\ln L] = 0 \end{cases}$$

otrzymamy

$$\alpha = \left[\frac{\sum x_i^\alpha \ln x_i}{\sum x_i^\alpha} - \frac{\sum \ln x_i}{n} \right]^{-1}, \beta = \left(\frac{\sum x_i^\alpha}{n} \right)^{1/\alpha}$$

Równań tych nie można wprost rozwiązać, aby otrzymać MLE estymatory $\hat{\alpha}$ i $\hat{\beta}$. Równania muszą być rozwiązywane stosując numeryczną procedurę iteracyjną.

Do oceny parametrów na podstawie próby za pomocą MNW w języku \mathcal{R} służy funkcja **fitdistr** z pakietu MASS. Działa ona dla prawie wszystkich opisanych wcześniej rozkładów (poza: jednostajnym, dwumianowym i hipergeometrycznym).

Przykład 9. Dla danych zawartych w zbiorze precip, zawierających informacje na temat ilości opadów dla 70 miast USA (1975 rok) wyznaczyć oceny parametrów rozkładu normalnego.

Rozwiązanie w języku \mathcal{R} .

fitdistr(precip,'normal')#oceny parametrów oraz ich błędy standardowe

```
-----  
mean          sd  
34.885714     13.608393  
(1.626514)    (1.150119)  
-----
```

Znacznie większe możliwości ma pakiet **fitdistrplus**, który pozwala estymować parametry za pomocą MNW oraz MM (funkcja **fitdistr**). Dla otrzymanego obiektu można użyć przeciążonych funkcji **plot** oraz **summary**, dostając w zależności od typu rozkładu (ciągły, dyskretny) wykresy diagnostyczne oraz wyniki testów statystycznych. Najciekawsza wydaje się funkcja **descdist**, która graficznie przedstawia dopasowanie rozkładu, oceniając skośność oraz kurtozę. Str. 197

5. Estymatory podstawowych charakterystyk liczbowych

A. Estymator wartości oczekiwanej. Średnia arytmetyczna jest estymatorem nieobciążonym i jednocześnie estymatorem największej wiarygodności wartości oczekiwanej zm. l. X przy spełnieniu przynajmniej jednego z poniższych założeń:

- liczba obserwacji n jest dostatecznie duża (zob. CTG),
- rozkład zmiennej X jest normalny.

B. Estymator wariancji. Jeżeli wartość oczekiwana m_X populacji X jest nieznana, to estymatorem nieobciążonym nieznanej wariancji w populacji X jest wariancja z próby, tj.

$$\hat{\sigma}_X^2 = S_n^2.$$

Jeżeli wartość oczekiwana m_X populacji X jest znana, to estymatorem nieobciążonym nieznanej wariancji dla danych szczegółowych jest statystyka S_n^2 określona wzorem:

$$S_n^2(\mathbf{X}, m_X) = \frac{1}{n} \sum_{i=1}^n (X_i - m_X)^2$$

C. Estymator wskaźnika struktury. *Wskaźnikiem struktury* w populacji $X \sim B(p)$ nazywamy prawd. p zaobserwowania wyróżnionej cechy w populacji. Estymatorem wskaźnika p jest częstość w próbie, tj. $\hat{p} = \bar{P}_n$, gdzie

$$\bar{P}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$X_i \sim B(p)$, n jest licznością próby.

6. Szeregi: szczegółowy, pozycyjny i rozdzielczy

Niech x_1, x_2, \dots, x_n będzie n -elementową próbą. Liczbę n jednostek wybranych do próby nazywamy *liczebnością próby*.

Jeżeli $n \leq 30$, to próbę nazywamy *małą próbą*.

Dane uporządkowane w ciąg niemalejący

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

tworzą szereg pozycyjny.

Jeżeli $n > 30$, to w celu ułatwienia analizy, dane grupuje się w klasy, tzn. przedziały, najczęściej jednakowej długości, przyjmując upraszczające założenie, że wszystkie wartości

znajdujące się w danej klasie są reprezentowane przez środek klasy.

Ustalenie liczby klas k zależy od liczby obserwacji n .

W literaturze podaje się różne sposoby ustalania liczby klas, np. dowolna liczba k spełniająca warunek:

$$\max\left\{5, \frac{\sqrt{n}}{2}\right\} \leq k \leq \min\{30, \sqrt{n}\}$$

Liczbę wartości próby zawartych w i -tej klasie nazywamy liczebnością i -tej klasy i oznaczamy n_i .

Reprezentant klasy \dot{x}_i oraz liczebność n_i dla $i = 1, 2, \dots, m$ tworzą ciąg par

$$(\dot{x}_i, n_i), i = 1, 2, \dots, k$$

zwany **szeregiem rozdzielczym**.

Wielkość

$$n_i^* = n_1 + n_2 + \cdots + n_i$$

nazywa się **liczebnością skumulowaną** i -tej klasy.

Wielkość $\frac{n_i}{n}$ nazywa się **częstością** i -tej klasy, a $\frac{n_i^*}{n}$ **częstością skumulowaną** i -tej klasy.

Pary (\dot{x}_i, n_i^*) , $i = 1, 2, \dots, k$, tj. środki kolejnych klas \dot{x}_i oraz ich liczebności skumulowane nazywamy **szeregiem rozdzielczym skumulowanym**.

Jeśli cecha jest typu dyskretnego, a liczba możliwych wartości jest bardzo duża, wtedy możemy postąpić podobnie jak w przypadku cechy typu ciągłego.

Średnią dla danych w postaci szeregu rozdzielczego nazywamy *średnią ważoną* i wyznaczamy ze wzoru:

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^k \dot{x}_i n_i$$

gdzie \dot{x}_i to liczba reprezentująca i -tą klasę, zaś n_i to liczebność i -tej klasy.

Wariancję dla danych w postaci szeregu rozdzielczego nazywamy wariancją ważoną i wyznaczamy ze wzoru:

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^k n_i (\dot{x}_i - \bar{x}_n)^2$$

7. Zestaw zadań W06

1. Wyznaczyć estymator parametru p w rozkładzie *Bernoulliego*.
2. Wyznaczyć MM oraz MNW estymatory parametrów rozkładu normalnego.
3. Wyznaczyć MNW estymator parametru rozkładu Poissona.
4. Celem sprawdzenia dokładności wskazań pewnego przyrządu pomiarowego dokonano 10 pomiarów tej samej wielkości fizycznej X i otrzymano następujące wyniki:
9,01; 9,00; 9,02; 8,99; 8,98; 9,00; 9,00; 9,01; 8,99; 9,00.

Dokonać przekształcenia pomiarów według wzoru:

$$Y = 100(X - 9).$$

Dla wielkości X i Y oszacować ich wartości oczekiwane i wariancje.

5. Wygenerować 50 elementową próbę prostą z populacji, w której cecha X ma rozkład o gęstości

$$f(x) = \frac{x}{8} \mathbf{1}_{(0; 4)}(x)$$

- a) Sporządzić histogram.
- b) Wyznaczyć wartość oczekiwaną i wariancję oraz ich oceny na podstawie wygenerowanej próby.

6. Korzystając z dostępnego oprogramowania wygenerować 100 elementową próbę według rozkładu

- a) `bin(20; 0,8)`,
- b) `nbin(3; 0,1)`,

c) Poisson(5).

Sporządzić histogram i dokonać ocenę punktową parametrów.

7. Wygenerować 100 elementową próbę według rozkładu logarytmiczno-normalnego z parametrami $\mu = 2,3$ i $\sigma = 0,5$.

a) Sporządzić histogram.

b) Dokonać estymacji parametrów, ocenić wartość oczekiwaną i wariancję oraz porównać te wartości z wartościami teoretycznymi.